

合计行。而向下钻取则相反，它从汇总数据深入到细节数据进行观察或增加新的维。例如，用户分析各地区的销售情况时，可以对某个城市的销售额细分为各个月份的销售额。通过钻取功能，用户对数据能更深入地了解，更容易发现问题，做出正确的决策。

(2) 切片和切块 (Slice and Dice)。切片和切块是在一部分维上选定值后，关心度量数据在剩余维上的分布。如果剩余的维只有两个，则是切片；如果剩余的维有三个以上，则是切块。例如，如果需要在图 5-7 中获取按月的销售数据，则属于数据切片，因为数据立方体按月份分成了数据片，形成了二维结构。但如果需要获取的是按地区的数据，例如，华东区（包括上海、南京、杭州等），华北区（包括北京、天津等），则属于数据分块，因为得到的数据是三维结构的。

(3) 旋转 (Pivot) 是变换维的方向，即重新安排维的放置（例如，行列互换等）。

3. 实现方法

OLAP 有多种实现方法，根据存储数据的方式不同，可以分为关系型 OLAP (Relational OLAP, ROLAP)、多维型 OLAP (Multidimensional OLAP, MOLAP) 和混合型 OLAP (Hybrid OLAP, HOLAP)。

ROLAP 表示基于关系数据库的 OLAP 实现。以关系数据库为核心，以关系型结构进行多维数据的表示和存储。ROLAP 将多维数据库的多维结构划分为两类表：一类是事实表，用来存储数据和维关键字；另一类是维表，即对每个维至少使用一个表来存放维的层次和成员类别等维的描述信息。维表和事实表通过主键和外键联系在一起，形成“星形模式”。对于层次复杂的维，为避免冗余数据占用过大的存储空间，可以使用多个表来描述，这种星形模式的扩展称为“雪花模式”。

MOLAP 表示基于多维数据组织的 OLAP 实现，以多维数据组织方式为核心。也就是说，MOLAP 使用多维数组存储数据。如果是三维数据，则其在存储中将形成数据立方体结构。

HOLAP 表示基于混合数据组织的 OLAP 实现，例如，低层是关系型的，高层是多维型的，这种方式具有更好的灵活性。

5.6.2 数据仓库概述

企业数据仓库的建设，是以现有企业业务系统和大量业务数据的积累为基础的。数据仓库不是静态的概念，只有将信息及时交给需要这些信息的使用者，供他们做出改善其业务经营的决策，信息才能发挥作用。而将信息加以整理归纳和重组，并及时提供给相应的管理决策人员，是数据仓库的根本任务。因此，从产业界的角度看，数据仓库建设是一个工程，是一个过程。

1. ETL 过程

针对现有各业务系统的数据，进行抽取、清理，并有效集成，按照主题进行组织，整个过程可以简称为抽取、转换和加载 (Extraction-Transformation-Loading, ETL) 过程。ETL 负责将分布的、异构数据源中的数据（例如，关系数据、平面数据文件等）抽取到临时中间层后进行清洗、转换和集成，最后加载到数据仓库或数据集中，成为 OLAP 和数据挖掘的基础。

数据仓库是一个独立的数据环境，需要通过抽取过程将数据从 OLTP 环境、外部数据源和脱机的数据存储介质中导入数据仓库。在技术上，ETL 主要涉及关联、转换、增量、调度和监控等几个方面。数据仓库系统中的数据不要求与 OLTP 系统中的数据实时同步，因此，ETL 可以定时进行。但多个 ETL 的操作时间、顺序和成败对数据仓库中信息的有效性至关重要。

2. 数据仓库的分类

从结构的角度看，有三种数据仓库模型，分别是企业仓库（Enterprise Warehouse）、数据集市（Datamart）和虚拟仓库（Virtual Warehouse）。

（1）企业仓库。企业仓库面向企业级应用，它搜集了企业的各个主题的所有信息，提供全企业范围的数据集成，数据通常来自多个操作型数据库和外部信息提供者，并且是跨多个功能范围的。企业仓库通常包含详细数据和汇总数据，数据量可达 TB 级。

（2）数据集市。数据集市面向企业部门级应用，它包含对特定用户有用的、企业范围数据的一个子集，它的范围限定在选定的主题中。根据数据来源不同，数据集市可以分为两种，分别是独立数据集市（Independent Datamart）和从属数据集市（Dependent Datamart）。

从属数据集市的数据直接来自于中央数据仓库，有利于保持数据的一致性，因为来自同一数据源，并且已经经过一致性处理和检验。从属数据集市的作用在于，为一些部门建立数据集市，将需要的数据复制、加工到其中，这样不仅可以提高部门的访问速度，也能满足部门的一些特殊的分析需求。

独立数据集市的数据直接来自于业务系统，由于为各个部门都建立了各自的数据集市，而当需要从整体上建立数据仓库时，由于各部门的特殊需要不同，不同数据集市中的数据表达也有所不同，将这种不一致的数据整合到一个中心数据仓库时，可能会遇到一些困难，例如，重新设计和各部门协调等。独立数据集市的优点是建立迅速、价格相对低廉。建立独立数据集市的原因往往是出于投资方面的考虑或工期的紧迫，或解决某部门的迫切需要。然而，需要注意的是，在设计其他部门的数据集市或中心数据仓库时，要充分考虑现有数据集市的设计，以避免由于设计的不一致性而造成后期整合的困难及昂贵的费用。

（3）虚拟仓库。虚拟仓库是操作型数据库上视图的集合。为了有效地处理查询，只有一些可能的汇总视图被物化。虚拟仓库易于建立，但需要操作型数据库服务器具有剩余的工作能力。

3. 非结构化数据与数据仓库

图 5-6 展示了数据仓库的体系结构，其中，第一步便是从多个数据源获取数据。这些数据源不仅限于企业内部的应用系统数据库。因为对于一个用于决策分析的系统而言，仅有企业内部数据是不够的。合理地采用外部数据（例如，报纸、期刊、电视等媒体的报道，一些商业机构的调查报告）能使分析和决策更为准确。而这些外部数据通常都是非结构化的数据。因此，如何用数据仓库管理非结构化数据，也是数据仓库应用中的一个重要问题。

为了更好地管理非结构化数据，数据仓库采用了元数据（当然，元数据不仅用于此），元数据可用于记录数据的文件标识符、进入数据仓库的日期、文件描述、文件来源、文件源的取得日期、文件的分类、索引字、清理日期、物理地址引用、文件长度和相关参考等信息。因此，管理人员可以通过元数据来获得非结构化数据的信息，在许多情况下，管理人员甚至不用看源