

统的并行度和计算效率。

(3) 并行处理。并行处理是指将一个任务分成多个子任务，并在多个计算单元上同时执行这些子任务。并行处理可以充分利用计算资源，从而快速完成任务。

(4) 内存计算。内存计算是指将数据存储在内存中进行计算，可以避免磁盘 I/O 和网络传输带来的延迟，从而大大提高计算效率。内存计算在处理大数据集时尤其有效，可以快速对数据进行计算和分析。

5. 高可用

大数据处理系统架构的高可用原则是指通过一系列有效的技术和策略，保证系统在面对各种故障和异常情况时能够继续保持可用状态。这些原则包括数据冗余、自动故障转移、负载均衡等。

(1) 数据冗余。数据冗余是指将数据复制到多个节点或存储设备中，保证数据的可靠性和可用性。当一个节点或设备发生故障时，系统可以自动切换到其他节点或设备上继续工作，从而保证系统的可用性。

(2) 自动故障转移。自动故障转移是指在一个节点或设备发生故障时，系统可以自动切换到其他节点或设备上继续工作，从而保证系统的可用性。这种方式可以通过一些专门的工具或框架来实现，如 ZooKeeper、Keepalived、Pacemaker 等。

(3) 负载均衡。负载均衡是指将工作任务分配到多个节点或计算单元上，以平衡每个节点或计算单元的负载，从而提高系统的可用性和性能。负载均衡也可以通过一些专门的工具或框架来实现，如 Haproxy、Nginx、LVS 等。

6. 稳定性

数据处理系统架构的稳定性原则是指通过监控和预警、性能调优、故障排除和升级等一系列有效的技术和策略，保证系统能够在长时间运行和高负载情况下保持稳定和可靠。

(1) 监控和预警。监控和预警是指对系统的各个组件进行实时监控，并在出现异常情况时能够及时发出警报，以便及时处理。通过监控和预警，可以及时发现系统的问题并进行调整，从而提高系统的稳定性。

(2) 性能调优。性能调优是指通过优化系统的各个组件和配置参数，以提高系统的性能和稳定性。这可以通过对系统进行定期性能测试和分析来实现，找到系统的瓶颈并进行优化。

(3) 故障排除。故障排除是指当系统出现故障或异常情况时，能够快速发现和解决问题，可以通过建立故障排除机制和团队来实现，使得问题能够快速定位和解决。

(4) 升级和维护。升级和维护是指及时更新系统的各个组件和软件版本，以保证系统的功能和性能不断提升。同时，也需要定期对系统进行维护和修复，以保证系统的长期稳定性和可靠性。

19.2.2 大数据处理系统架构类型

大数据处理系统的体系结构可以根据数据处理方式分为不同的类别。

1. 批处理架构

批处理架构是一种数据处理系统架构类型，它主要用于处理大规模数据的批量处理任务，

该任务通常在离线模式下执行，具有较高的吞吐量和较低的实时性。批处理架构通常包括数据采集、数据存储、数据管理和数据输出等四个核心模块。

在批处理架构中，数据采集模块主要负责将原始数据从不同来源收集到集中式存储中，常见的采集方式包括文件传输、日志收集和数据接口等。数据存储模块则是存储批处理任务所需的数据，包括原始数据、中间结果和最终结果等。常见的存储方式包括关系型数据库、分布式文件系统和 NoSQL 数据库等。数据管理模块是批处理架构的核心，它主要负责对原始数据进行加工、分析和处理，通常采用分布式计算技术，如 MapReduce、Spark 等。最后，数据输出模块将处理后的结果输出到指定的存储或数据仓库中，通常包括关系型数据库、NoSQL 数据库、分布式文件系统等。

在批处理架构中，大数据集被划分为多个数据组，整个组在未来的时间进行处理。何时处理每个组可以用多种方式来确定，例如，它可以基于预定的时间间隔（如每 5min 处理已被收集的数据）或某些触发条件（如只要它包含 5 个数据元素或一旦它拥有超过 1MB 的数据则进行处理）。基于预定的时间间隔的批处理过程如图 19-1 所示。




图 19-1 批处理过程

批处理架构的优点在于能够处理大规模数据，具有较高的吞吐量和稳定性。同时，批处理任务通常在离线模式下执行，可以充分利用计算资源，提高计算效率。缺点在于实时性较差，无法满足对数据的实时分析和处理需求。

2. 流处理架构

流处理架构是指数据以连续的、无限制的方式流式处理，即每条新数据都会在到达时进行处理，而不是像批处理架构一样按照固定的时间间隔来处理。流处理过程如图 19-2 所示。




图 19-2 流处理过程

流处理架构可以快速处理实时数据，实现低延迟的数据处理和实时反馈。流处理架构通常使用类似 Apache Flink、Apache Storm 等开源流处理引擎来实现。在流处理架构中，数据可以被连续地读取、处理和输出，这样就可以对连续的数据流进行实时处理。流处理框架通常由两个主要组件组成：数据流和运算符。数据流表示无限制的数据集合，而运算符用于处理数据流。