

务，而 HBase 采用列族的方式平衡 OLTP 和 OLAP，支持水平扩展，如果数据量比较大，对性能要求没有那么高，并且对事务没有要求的话，HBase 也是个不错的选择。ES 默认对所有字段都建了索引，所以比较适合复杂的检索或全文检索。

19.3.2 数据管理

数据管理是系统中必不可少的非功能模块之一，主要负责系统数据整体的稳定性和安全性，同时提供一些系统的监控指标作为系统的功能情况进行反映。在大数据处理系统中，数据管理通常分为以下 4 部分，分别是元数据管理、数据关系图谱、数据安全和资源监控。良好的大数据处理系统会结合数据和系统进行统一管理，保证系统和数据两方面的安全性和稳定性。

1. 元数据管理

元数据就是描述数据的数据，它为系统的各类数据提供了上下文环境，使系统能够更好地了解、管理和使用数据。

现在数据对于公司的决策十分重要，随着业务的发展，业务线会慢慢庞大起来，随着开发人员的变更以及增多，没有元数据治理，很难保证数据质量，这时候就需要元数据管理，用来记录公司拥有什么数据，数据在哪里、由谁负责，数据中的值意味着什么，数据的生命周期是什么，哪些数据安全性和隐私性需要保护，以及谁使用了数据，用于什么业务目的，数据的质量怎么样，等等。

元数据一般分为两类，分别是技术元数据和业务元数据。

(1) 技术元数据是存储关于数据仓库系统技术细节的数据，是用于开发和管理数据仓库使用的数据。对开发人员来说，它有助于明确数据的存储、结构，有助于厘清数据关系，能够提升开发效率，还有助于了解数据的来源和去向并进行分析，支持数据血缘追溯和影响分析。

(2) 业务元数据描述数据的业务含义、业务规则等，可以为数据应用提供更好的服务。

在大数据处理系统中，元数据管理主要分为以下 7 种管理方式。

1) 数据源元数据

数据源元数据主要是数据库模型设计文档、为综合统计分析平台提供数据的各种业务系统的数据字典及数据接口文件等。数据源元数据的管理主要由相关人员对各类文档进行统一版本的管理。

2) ETL 规则元数据

ETL 规则元数据中涉及数据源元数据、目标系统元数据、ETL 流程、源与目标的映射关系等元数据信息。数据源元数据包括业务系统元数据和数据仓库元数据等；目标系统元数据可能是数据仓库元数据、数据集市元数据等。ETL 规则元数据的管理主要由数据库开发人员根据各个模块的 ETL 过程以及过程运行的顺序，形成相关元数据管理文档进行统一管理。

3) 数据仓库元数据

制定数据仓库模型设计文档记录事实表、维度、属性、层次等信息，物理表与多维模型的映射关系等信息，对文档进行统一版本的管理。

4) 报表元数据

报表元数据包括对报表和报表中具体指标（度量）的描述信息等。报表元数据的管理：对数据集上可以计算的度量进行相关元数据的管理，包括详细设计文档中对各个表中度量的定义、描述等；对所有表和度量之间的关系进行严格的文档记录，包括度量的计算、度量之间的相互依赖关系，以及历史信息进行元数据管理。

5) 接口文件格式元数据

接口数据文件格式，包括接口数据文件的命名、传输周期、格式等说明信息。接口文件格式元数据主要与 ETL 规则元数据进行统一管理。

6) 商业元数据

系统中对各项指标的业务含义的描述性信息，在综合统计分析平台中，包括业务含义描述，主题的分析目标描述，报表指标的解释信息等。商业元数据的管理可以分解成数据仓库元数据的管理和报表元数据的管理。

7) 其他元数据

数据访问日志、数据装载日志等信息。数据访问日志记录数据库的访问信息，包括对数据库表的操作、锁、内存使用、I/O 使用等信息；数据装载信息记录每个 ETL 过程的抽取时间、操作人员、起始和截止时间、抽取涉及的表、操作行数等相关信息。其他元数据的管理：将元数据信息记录到日志，形成元数据文件进行统一管理。

2. 数据关系图谱

在大数据处理系统中，数据关系图谱主要记录了数据之间的关联关系和血缘关系。利用数据关系图谱中记录的知识和信息，可以快速得到数据之间的关系，进而在数据分析时更准确高效地分析出数据背后的价值。

数据血缘关系和关联关系属于数据治理中的概念，是在数据溯源的过程中找到相关数据之间的联系，它是一种逻辑概念。

数据治理里经常提到的一个词就是血缘分析，血缘分析是保证数据融合的一个手段，通过血缘分析实现数据融合处理的可追溯。大数据的数据血缘是指数据产生的链路。直白地说，就是数据是怎么来的，经过了哪些过程和阶段。

任何的数据，从产生、ETL 处理、加工、融合、流转，到最终消亡，数据之间自然会形成一种关系。可用人类社会中的人际关系来表达数据之间的这种关系，称之为数据的血缘关系。

从技术角度来讲，数据 a 通过 ETL 处理生成了数据 b，那么，数据 a 与数据 b 具有血缘关系。不过与人类的血缘关系略有不同，数据血缘关系还具有一些个性化的特征。

在数据的处理过程中，从数据源头到最终的数据生成，每个环节都可能会导致数据质量问题。例如，数据源本身数据质量不高，在后续的处理环节中如果没有进行数据质量的检测和处理，那么这个数据信息最终流转为目标表时，它的数据质量也是不高的。也有可能某个环节的数据处理中，对数据进行了一些不恰当的处理，导致后续环节的数据质量变得糟糕。因此，对于数据的血缘关系，要确保每个环节都注意数据质量的检测和处理，那么后续数据才会有优良的基因，即有很高的数据质量。

血缘关系包含以下4个基本特征：

(1) 归属性。特定的数据归属特定的组织（或个人），数据具有归属性。

(2) 多源性。同一个数据可以有多个来源，一个数据可以是多个数据经过加工而生成的，而且这种加工过程可以是多个。

(3) 可追溯性。数据的血缘关系，体现了数据的生命周期，体现了数据从产生到消亡的整个过程，具备可追溯性。

(4) 层次性。数据的血缘关系是有层次的。对数据的分类、归纳、总结等进行描述的信息又形成了新的数据，不同程度的描述信息形成了数据的层次。

一般来说，数据都归属于某个组织或者某个人，数据都有所有者。数据在不同的所有者之间流转、融合，形成所有者之间通过数据联系起来的一种关系，是数据血缘关系的一种，在层次结构中处在最上层。这种关系，清楚地表明了数据的提供者和需求者。

数据库、表和字段，是数据的存储结构。不同类型的数据，有不同的存储结构。存储结构决定了血缘关系的层次结构。所以，不同类型数据的血缘关系层次结构有些差别。相比之下，结构化数据血缘关系的层次结构比较简单，对于非结构化数据，如以文件服务器存储的数据来说，血缘关系的层次结构会略有不同。不同层级数据的血缘关系，体现着不同的含义。所有者层次体现了数据的提供方和需求方，其他的层次则体现了数据的来龙去脉。通过不同层级的血缘关系，可以很清楚地了解数据的迁徙流转，为数据价值的评估、数据的管理提供依据。

在关联关系领域，目前的大数据处理系统主要使用一些关联分析算法进行数据背后价值的挖掘和展示，这些算法使用适当的统计分析方法对收集来的大量数据进行分析，提取有用信息并形成结论，进而对数据加以详细研究和概括总结。这一过程也是质量管理体系的支持过程。在实用中，数据分析可帮助人们作出判断，以便采取适当行动。这种针对数据背后的价值进行发现的工作也称作数据挖掘。

数据挖掘一般是指从大量的数据中通过算法搜索隐藏于其中信息的过程。数据挖掘通常与计算机科学有关，并通过统计、在线分析处理、情报检索、机器学习、专家系统（依靠过去的经验法则）和模式识别等诸多方法来实现上述目标。

数据挖掘（Data Mining）是从大量的、不完全的、有噪声的、模糊的、随机的数据中提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识的过程。

根据信息存储格式，用于挖掘的对象有关系数据库、面向对象数据库、数据仓库、文本数据源、多媒体数据库、空间数据库、时态数据库、异质数据库以及 Internet 等。

3. 数据安全

在大数据处理系统中，对数据和资源的请求必须严格遵守数据安全体系。一般将系统的数据安全定义为：数据安全 = 认证 + 授权。

认证主要是对用户的身份确认，如最简单的用户登录需要账户和密码；如登录 MySQL 需要输入用户名和密码。例如，大数据中使用的 kerberos 的认证框架的认证管理。

授权是指用户可以访问的资源。例如，授权用户张三不能访问 ods 层的表，可以访问 dwd 层和 dws 层的表。又如，Java 中基于角色的身份认证，基于角色的权限控制（Role-Based Access Control, RBAC）。再如，大数据中使用的 Sentry 和 Ranger 授权框架的权限管理。

一般意义上的数据安全流程如下：

- (1) 数据的产生：通过数据分级体系对敏感字段打标签。
- (2) 数据的存储：需要通过加密的方式存储相关数据，避免直接存储原格式的数据。
- (3) 数据的使用：包括一个独立的权限控制系统。
- (4) 数据的传输：相关的申请与查询操作需要通过专门的 API 接口进行，并且有高安全等级的加密措施。
- (5) 数据的展示：在申请通过后，根据申请人的安全等级，展示对应等级的数据。
- (6) 数据的销毁：敏感数据仅在 HDFS 上做逻辑删除是不够的，需要配合物理删除同步清理敏感数据。

使用传统的数据仓库进行举例，一般情况下，数据仓库部门对外开放的表是 ads 层，可能由于需要可以申请 dw 层的数据，但是 ods 层的原始数据是不会对外开放的。对于这些对外开放的表也会有安全等级的划分。表安全设置为 4 个等级：

- S4：非业务核心表，删除对于其他计算任务无影响。
- S3：非业务核心表，但删除对于其他计算任务有一定的影响。
- S2：业务核心表，仅限本部门使用，删除对于其他部门使用无影响。
- S1：业务核心表，删除对于其他部门使用有影响。

在大数据领域的数据安全中，大数据安全分析工具最重要的功能特性包括 5 个因素，这些安全分析工具包括 Cybereason、Fortscale、Hexis Cyber Solutions、IBM、LogRhythm、RSA 和 Splunk。这 5 个因素包括统一的数据管理、支持多种类型的数据（包括日志、安全漏洞和网络流）、可扩展的数据获取、专门针对信息安全的分析工具、合规报告。

4. 资源监控

大数据监控是指通过大数据技术手段获取、收集、分析数据，并能够准确分析信息，有效预测信息发展动态趋势。大数据监控主要围绕海量全网数据，大多数需要借助监测系统来协助分析数据。大数据运维监控的维度和主要监控项如表 19-2 所示。

表 19-2 大数据运维监控体系表

监控维度	主要监控项
底层基础监控	机房与网络（路由器、交换机等）、专线、服务器（CPU、内存、IO、磁盘、文件等）各类型日常的基础监控
服务状态监控	各类型标准组件存活状态（从业务的 SLB、Nginx、Java、HDFS、Hive、ZK 等组件存活状态）
组件性能监控	每种组件的 Metrics 性能监控，以 Hive 为例（QPS、RPC、Metastore Canary、connection 等）
Runtime 监控	顾名思义，模拟客户端去不间断循环与各式组件发起基本请求与操作，确认组件状态，如每隔 5 分钟与 HDFS 交互，完成新增、修改、删除、查询等基本操作，并获得操作结果状态与响应时间
集群指标监控	集群的核心指标监控，如文件大小分布、集群整体计算资源、集群整体存储资源等指标
任务状态监控	任务状态、任务占用资源、任务延迟等
趋势预测监控	存储与计算同比、环比上涨趋势，小文件同比、环比上涨趋势，SLA 趋势预测