

其实，表 19-2 涉及的每个维度都包含很多监控项与监控指标，而针对不同的告警维度，它的监控对象也不尽相同，但总体来说，对于大数据监控，一般可分为资源监控和性能监控两方面。

从监控的方式看，有些监控操作不断读取系统状态，如常见的 CPU、内存，然后设定阈值触发告警动作；有些监控操作是需要有时序性的聚合统计，如 HDFS 存储增量，当增量斜率比平时高时触发告警动作；还有一些监控操作是需要和其他监控操作进行联动，同时满足条件才会触发告警动作。

19.3.3 数据处理

随着计算机的日益普及，在计算机应用领域中，数值计算所占比重很小，通过计算机数据处理进行信息管理已成为主要的应用。

从数据类型角度，将大数据处理中的数据类型分为以下 3 种：结构化数据一般指关系数据库的数据，具有固定的数据模式；半结构化数据指具有一定的数据结构但数据模式不固定，如 JSON、XML、HTML、日志文件；非结构化数据指图片、视频、文本、语音等。

从大数据处理系统的数据处理方式来看，将大数据处理中的处理方式分为两种类型，即离线数据处理和实时数据处理。离线数据处理是利用离线同步工具通过定时任务将数据从数据源按照全量和增量形式同步到离线存储平台 Hive 中；实时数据处理一般是埋点、日志数据、binlog 以及 nsq 消息等通过实时同步工具同步到 Kafka 平台中。

1. 实时计算处理

实时计算处理是当下大数据处理领域发展中最为关注的部分，实时计算处理主要用于处理流式数据。在大数据处理系统中实时流式处理问题的特点如下：

- (1) 数据源源不断的到来。
- (2) 数据需要尽快得到处理，不能产生积压。
- (3) 处理之后的数据量依然巨大，是 TB 级甚至 PB 级的数据量。
- (4) 处理的结果能够尽快展现。

以上四个特点可以总结为：数据的收集 -> 数据的传输 -> 数据的处理 -> 数据的展现。

其中，数据的处理一般涉及数据的聚合，数据的处理和展现能够在秒级或者毫秒级得到响应。针对这些问题目前形成了 Flume+kafka+Storm/Spark+Hbase/Redis 的技术架构。

一般来说，实时处理场景的数据从数据源产生后，它就立马交给流处理任务去处理。计算任务可以是 Java 编写，也可以是 Python 编写，不管是哪种流处理计算任务，它都需要 7×24h 不中断运行，才能保证数据的及时处理。

处理得到的结果，可以实时进行存储与更新，从而让外部服务去做实时的调用与展示。因为数据源的数据是实时产生的，所以从流处理任务的视角来看，它一定没有边界的。它实时在产生，好像没有边界，一直在流动过来。处理这种无界的数据称为实时处理。从传统意义上讲，数据处理还可以分为流处理和批处理。

处理这种实时数据时，一般会采用流处理的方式。所以，一般将离线批处理和实时流处理

一起介绍。离线场景适合批处理运算，实时场景适合流处理运算。批处理运算其实是把这个数据拿到之后，先让整体数据通过第一个阶段的处理，得到最终的结果以后再送往下一个阶段进行处理。也就是说，采用批处理方式时，在任意一个时间点去观察，可以发现所有的数据一定同时处在某一个阶段。

流处理方式则不同。流处理方式就和流水线的工人一样，第一个工人负责第一个阶段，第二个工人负责第二个阶段，以此类推。它们在等待数据传输过来，数据过来之后就开始处理，处理完成后马上将处理结果送给下一个阶段。然后继续等待新的数据传输进来。有数据之后就处理，处理完以后交给下一个阶段。每个阶段都是重复上述动作。采用流处理这种方式，在任意一个时间去观察，可能会发现多个阶段都会有数据存在。这是它们的不同之处。

离线批处理和实时流处理的概念，大家一定要区分清楚。离线处理和实时处理，主要是针对数据是否有界。有界就是离线处理，无界就是实时处理。离线的数据适合批处理这种处理方式去做计算，实时数据适合流处理这种方式。

典型的离线批处理场景有数据仓库、搜索与检索、图计算、数据分析，这些都属于离线场景。而实时处理场景，有实时数仓、实时数据分析、流上机器学习等，所有需要实时处理的任务都属于这个场景。

2. 离线计算处理

离线计算是大数据处理系统中使用最广泛最频繁的数据处理方式，由于大数据处理系统本身针对数据量十分庞大且较为复杂的处理流程，一般使用离线处理大批量的数据是较为合理的数据处理方式。大数据离线处理具有以下4个特点：

- (1) 数据量巨大且保存时间长。
- (2) 在大量数据上进行复杂的批量运算。
- (3) 数据在计算之前已经完全到位，不会发生变化。
- (4) 能够方便地查询批量计算的结果。

在大数据处理系统中，离线计算处理常常使用多台机器进行分布式处理，将多台机器处理得到的结果进行同步是必不可少的关键步骤。常用的离线同步工具有 sqoop、datax 以及自己写的同步程序。

同步工具的基本原理为：工具一般可以抽象成 source->channel->sink 构成，以不同的插件形式组装成一个完整的同步工具。例如，MySQL source 插件、Hive sink 插件用于来读取 MySQL 以及插入 Hive，底层是调用 MySQL 和 Hive 的读写 API 完成操作，可自定义不同数据源的读写插件。channel 一般有内存和文件两种类型，在 source 和 sink 起到缓冲持久化作用，保证数据的可靠性。离线处理的过程可以在不同的节点上部署多个数据同步工具实现分布式多线程运行，以及大批量数据的导入导出，从而提升速度。

与在线计算当前呈现出各种框架和架构不同，离线处理目前在技术上已经成熟，它使用 HDFS 存储数据，使用 MapReduce 做批量计算，计算完成的数据如需数据仓库的存储，直接存入 Hive，然后从 Hive 进行展现。

离线计算处理主要还是利用 Hadoop 分布式存储 + 分布式运算的框架，可以对海量数据进行统计分析，解决单节点极限性。