

例如，通过编写 MapReduce 可以批量统计某个地域的车辆里程情况、道路等级，通过速度判断车型、车辆驾驶情况等，然后使用 Hive 做数据仓库，可以统计最近一年或者两年的数据，进行数据的建模以及历史数据的统计和分析。

离线计算处理最大的优点就是可持续性，当数据存储后可以直接断网。即使网络中断也能完成这部分数据的处理。同时，离线计算处理的是有界的数据。

3. 图计算处理

关于图计算，其实不能单从字面上去理解。所谓图计算的“图（Graph）”，其实指的是一种网络，是一种适合表现事物之间关联关系的数据结构，而非大众意义上的图片（Image）。

图计算目前广泛应用于公安系统和银行金融领域。通过社交网络分析，可以打击犯罪团伙，金融欺诈、信用卡盗刷等。通过人与人之间的关联关系推断，还可以用于理财产品推荐等场景。

图的基本组成是顶点和边。根据边是否有方向，图可以分为有向图和无向图。有向图的边从源顶点出发，指向目标顶点。在无向图中，一个顶点上边的数量叫作这个顶点的度。在有向图中，一个顶点上出发的边的数量叫作这个顶点的出度，汇集到一个顶点上的边的数量叫作这个顶点的入度。如果有向图中存在一些边构成闭合的环，称为有环图，反之为无环图。有环图上设计算法需要考虑终止条件，否则算法可能会沿着环永远循环下去。如果两个顶点之间可以有 multiple 平行边，则称为多重图。如果存在自环，即由一个顶点指向自己的边，则称为伪图。Graphx 的图都是伪图。如果顶点和边是包括属性的，称为属性图，否则是非属性图。非属性图的作用不大。通常顶点和边至少有一个是包括属性的，Graphx 的图都是属性图。如果图的顶点被分成两个不同的子集，边的源顶点始终来自其中一个子集，目标顶点始终来自另外一个子集，则这种图称为二分图。

如果图的边是没有属性的，可以用稀疏的邻接矩阵进行表示。在 Graphx 中，用顶点属性表 VertexRDD 和边属性表 EdgeRDD 联合来表示图。

常见的图算法大致可以分为以下 3 种：

- (1) 路径搜索算法，如 DFS&BFS、最短路径、最小生成树、随机游走等。
- (2) 中心算法，如 DegreeCentrality、ClosenessCentrality、BetweennessCentrality、PageRank 等。
- (3) 社群发现算法，如 MeasuringAlgorithm、ComponentsAlgorithm、LabelPropagationAlgorithm、LouvainModularity Algorithm 等。

目前在大数据领域，Spark 框架对于图的计算和处理能力较为优秀。在 Spark 框架下，除了支持批处理和流处理，也提供图计算功能，而图计算功能主要由 Spark GraphX 来提供。而近些年，图计算在大数据领域也得到越来越多的应用。

19.3.4 数据分析

大数据处理系统最重要的功能就是提供强大的数据分析能力，通过前文提到的数据存储、数据管理、数据处理步骤后，最后需要对得到的数据进行科学的分析和衡量，给出针对性的意见和方案。目前，大数据处理系统的数据分析给各行各业都提供了强大的信息支持，帮助很多行业实现了数字化和智能化的转型，加快了企业的发展，帮助企业更好地进行分析决策和解决问题。

1. 机器学习

机器学习使计算机能够从研究数据和统计信息中学习。而人工智能是一个宏大的愿景，目标是让机器像人类一样思考和行动，既包括增强人类脑力也包括增强人类体力的研究领域。一般将传统的机器学习分为以下3类：

（1）监督学习。监督学习是指给算法一个数据集，并且给定正确答案。机器通过数据来学习正确答案的计算方法。

（2）非监督学习。非监督学习中，给定的数据集没有“正确答案”，所有的数据都是一样的。无监督学习的任务是从给定的数据集中，挖掘出潜在的结构。

（3）强化学习。强化学习主要由智能体（Agent）、环境（Environment）、状态（State）、动作（Action）、奖励（Reward）组成。智能体执行某个动作后，环境将会转换到一个新的状态，对于该新的状态环境会给出奖励信号（正奖励或者负奖励）。随后，智能体根据新的状态和环境反馈的奖励，按照一定的策略执行新的动作。上述过程为智能体和环境通过状态、动作、奖励进行交互的方式。

机器学习往往需要大量的数据样本作为支持，而大数据处理系统中可以获得大量的相关数据，将这些数据经过筛选和处理后投入预先设定好的机器学习算法中，就可以获得机器学习的结果，从而服务于行业内部后续的决策。

2. 搜索推荐

在大数据处理系统中，由于内部存储的数据十分庞大和复杂，整体搜索推荐的消耗不像传统的 Web 项目一样方便和快捷，针对大数据处理系统的搜索和推荐，需要引入专业的组件进行处理，常见的组件包含以下内容：

（1）ElasticSearch。Elasticsearch 是一款非常强大的开源搜索引擎，具备非常多的功能，可以从海量数据中快速找到需要的内容。它是一个基于 Lucene 构建的开源、分布式、RESTful 搜索引擎。设计用于云计算中，能够达到实时搜索、稳定、可靠、快速，安装使用方便。支持通过 HTTP 使用 JSON 进行数据索引。Elasticsearch 结合 Kibana、Logstash、Beats，也就是 elastic stack（ELK），被广泛应用在日志数据分析、实时监控等领域。Elasticsearch 底层是基于 Lucene 来实现的，具有易扩展、高性能的优势。同时，ElasticSearch 提供了倒排索引的 API 和使用模式，所以擅长海量数据的搜索、分析和计算。

（2）Apache Solr。Apache Solr 是一个基于 Lucene 的 Java5 开发的高性能、全文搜索服务器。Solr 是一个独立的企业搜索应用服务器，目前很多企业使用 Solr 开源服务。它使用 XMLoverHttp 将文档添加到搜索集合中，通过 HTTP 接收 XML/JSON 响应也可以查询集合。Apache Solr 中的资源是以 Document 为对象进行存储的。每个文档由一系列 Field 构成，每个 Field 表示资源的一个属性。Solr 中的每个 Document 需要有能唯一标识其自身的属性，默认情况下这个属性的名字是 id，在 Schema 配置文件中 id 进行描述。

Apache Solr 的主要功能包括高效灵活的缓存、垂直搜索、突出显示搜索结果、通过索引复制提高可用性、用于定义字段、键入和设置文本分析的强大数据模式集，以及基于 Web 的管理界面。