

(3) Nutch。Nutch 是 Apache 旗下的一个用 Java 实现的开源索引引擎项目，通过 Nutch，诞生了 Hadoop、TIKA、GORA 等开源框架。

相对于那些商用的搜索引擎，Nutch 作为开放源代码搜索引擎将会更加透明，从而更值得大家信赖。现在所有主要的搜索引擎都采用私有的排序算法，而不会解释为什么一个网页会排在一个特定的位置。除此之外，有的搜索引擎依照网站所付的费用，而不是根据它们本身的价值进行排序。与它们不同，Nutch 没有什么需要隐瞒，也没有动机去扭曲搜索的结果。Nutch 将尽自己最大的努力为用户提供最好的搜索结果。它具备以下优势：可以对索引文件进行每秒上千次的搜索，能够提供高质量的搜索结果，节约成本，以最小的成本运作。

3. 数据可视化

通过可视化将大数据处理系统的分析结果进行展示是必不可少的步骤，通过图表展示的内容可以帮助用户更加直观地进行分析和决策。在大数据领域一般使用下列可视化工具：

(1) Silk。针对交互式表格或地图，Silk 是一款比 Tableau 简单得多的数据可视化和分析工具。它只需点击几下鼠标，即可创建交互式地图和图形，为数据赋予活力。Silk 还可以与多人协作处理可视化。

(2) Tableau。一种可以制作散点图、柱状图、地图和其他内容的工具。Tableau 是一款数据可视化工具，主要侧重于商业智能。它可以创建图形、条形图、散点图及更多视图，不需要编程。它新发布的一款 Web 连接件，可以连接到数据库或 API，从而能够通过可视化呈现活动数据。

(3) Datawrapper。一款开源工具，可在几分钟内创建嵌入式图形。由于是开源的，它会不断完善，因为任何人都可以为它贡献代码。它有一个出色的图形库，用户可以浏览别人用 Datawrapper 能制作出的图形。

(4) Chartio。Chartio 可以在浏览器中合并数据源、执行查询。只需通过点击就可以创建强大的仪表板。Chartio 的可视化查询语言让任何人都能从任何地方获取数据，没必要知道 SQL 或其他复杂的模型语言。它还可以调度安排 PDF 报告，从而可以导出仪表板，并以 PDF 文件的格式通过邮件发给任何人。Chartio 的另一个优点是，它常常不需要数据仓库。这意味着，可以更迅速地搭建并运行起来，实施成本会更低，更易于预测。

19.3.5 系统部署

大数据处理系统的部署是个复杂的过程，涉及内容众多，但无论如何都是以需求为导向的。所以，首先需要从需求中抽取出影响点，如实际运行时大概的数据量，实时性要求，高可用方面的要求，等等。进而依据上述要求来考虑硬件的选型、平台软件的版本选择、部署时组件的配合以及组件自身针对业务形态进行的优化配置。

一般来说，对于硬件往往是配置越高越好，但同时也关注效费比等经济性方面的问题。因此在进行大数据部署时也需要寻找一个经济上的均衡点，让硬件能最大效率地发挥其功能和性能。

1. 部署分析

大数据处理系统的部署需要针对以下几个特点进行分析：需求分析、模型设计、硬件规划、软件规划。

需求分析主要了解系统将来运行的上层业务的业务特点以及重点。一般来说，大数据的业务类型基本分为离线业务和在线业务。离线业务主要为 MapReduce，进行数据的分析、计算和处理；在线业务主要为 HBase，HBase 对外提供实时的数据查询业务。当然上层业务也可能基于 Hive 来处理，但 Hive 实质上还是基于 MapReduce。

在需求分析的过程中能够了解系统业务运行时的数据量，分析数据模型，包括已有的数据量、后续单位时间内增加的数据量，以及系统投入使用后期望的数据保存时间等要求。

模型设计主要基于系统总体的数据量等信息设计存储和计算模型。例如，考虑数据的存储方式是通过 HDFS 进行存储还是通过 HBase 进行存储，或者两者兼而有之。如果目标数据较为离散，并且只有存储的简单要求，一般单纯采用 HDFS 即可满足要求。如果目标数据存在外部查询用途，且实时性要求较高，则可以考虑采用 HBase 进行存储，通过 HBase 对外提供在线查询业务。通过不同的模型设计选择不同的部署方式和部署策略。

硬件规划主要基于用户的需求进行硬件规划、部署设计，以及 IP 地址的规划。需要考虑每台服务器单节点的性能要求。例如，计算要求高，则 CPU 和内存的配置要求也较高，同时在部署设计上需要把计算节点独立出来，避免存储节点占用过多 CPU，导致计算延迟。又如，存储要求高，则需要加大磁盘的容量，在部署设计上可以多 DataNode 节点分担文件读写压力，同时将计算节点和 DataNode 节点合并设置，以减少服务器数量。

同时，在硬件的选取上也需要进行考量，市场上有各种类型的磁盘，性能上存在差异，所以还要考虑磁盘类型的选择。一般来说选用 sas 盘较多，性能要求较低可考虑 sata 盘，性能要求较高可考虑采用 ssd 盘。另外，还可以通过 raid 来辅助实现磁盘性能的提升以及高可靠性的提升。

再者，平台的整体部署离不开高性能网络的支撑，所以网络建议采用万兆网，既可以降低网络部署的复杂性，也可以提高可维护性。特殊情况下，也可以采用多网口绑定的方式，但是往往会大幅提高网络部署的复杂性。

软件规划主要根据系统支持的业务，规划采用哪些组件来满足用户的功能要求，并且通过部署来实现业务的高可用，高可扩展。同时，在各个节点部署服务时，还要注意服务间的依赖关系。例如，HDFS 的 QJM 方式的 HA 实现，对 ZooKeeper 有依赖。

2. 部署原则

一个大数据处理系统增量的部署代表大数据项目的一个重要里程碑。一个合格的大数据处理系统的部署为最终用户提供了内容和功能以及立竿见影的收益，但是如果部署的计划不好、错误很多，而且执行效率不高，那么用户会很不满意，为了确保大数据处理系统的顺利部署，项目团队在准备交付一个增量时，应该遵循如下关键原则：

（1）生产环境和测试环境的隔离。系统环境分为生产环境和测试环境。其中生产环境用于实际运营，承载真实业务数据和业务应用；测试环境用于各种功能验证和性能测试等，包括应用在上线前的功能验证。如把两个环境合用，将带来很多不确定性，测试环境容易对生产环境造成干扰，影响生产环境正常业务的提供，甚至测试环境中不成熟的应用和业务运行时可能对环境造成破坏性的影响。因此，对两个环境进行物理隔离，两者独立运行，互不干扰，防止因

硬件资源的占用或者抢夺对运行造成不必要的影响。

(2) 不同集群的隔离。为避免可能存在的机架断电导致集群数据丢失或者停止服务，需要将属于同一个集群的不同节点分别部署到不同的机架上，通过多个机架的方式提供对服务器的承载。每个集群都基于一套独立的 HDFS 运行，这样从物理上和逻辑上与其他集群都进行了隔离。

(3) 在线应用和离线应用的隔离。在大数据平台上运行的应用分为在线应用和离线应用两大类。为保证重点在线应用的正常运行，需要单独规划 HBase 集群，且该集群基于一套独立的 HDFS 运行，从物理上和逻辑上与其他集群都进行隔离。

(4) 不同在线应用的隔离。对于在线应用，分为一般在线应用和重点在线应用，重点在线应用基于一套独立的 HDFS 运行，实现物理隔离，用于存储重要的在线数据，保证实时查询服务的持续提供。一般在线应用用于提供普通的 HBase 查询，对实时性的要求低于重点在线应用，所以可与离线应用部署在一个集群中。

(5) 不同应用数据的隔离。集群中的数据都是基于 HDFS 进行存放的，因此对于属于同一个集群内的应用的数据隔离，可通过设置不同的 HDFS 目录存放的方式实现不同应用数据的隔离，不同应用属于不同的用户，不同的应用使用不同的目录，然后通过对目录进行权限配置的方式进行隔离和共享。各个应用在自身所属的目录下设置子目录，以及数据计算所需的输入（如 Input）和输出（如 Output）的目录名称等。

3. 部署环境

大数据处理系统主要是作为服务端提供服务进行使用，操作系统的选择没有专门的限制和要求。尽管 Windows 家族产品中的其他操作系统（如 Windows XP）也支持一定的 Web 应用发布能力，但一般只用作平时的开发测试及学习。一般大数据处理系统的操作系统主要还是在各类 UNIX（如 Linux）上进行部署并提供服务。

目前，主流的各类应用服务器在大数据处理系统的部署上已经得到了广泛的应用。如今，各大主要软件厂商纷纷将应用服务器作为其电子商务平台的基础。由于应用服务器本身是一个正在不断发展的概念，不同的产品之间有很大的差别，但是其核心结构，以及需要解决的主要问题都是相近的，区别仅在于各个产品解决的具体方法不同。下面是应用服务器共同需要解决的部分问题：

(1) 集群规划。大数据处理系统需要多台服务器共同协作来实现功能的完成，选择主从模式的服务器是集群规划的不二之选。如何将集群进行划分和规划是首先需要考虑的因素。

(2) 网络配置。在大数据处理系统的部署中，需要对集群节点进行网络配置。

(3) 安全配置。大数据处理系统的机器一般选 Linux 作为操作系统。作为一个开放源代码的操作系统，Linux 服务器以其安全、高效和稳定的显著优势而得以广泛应用，最重要的安全模块有 SELinux 和 iptables 或 firewallld。

(4) 时间同步。大数据处理系统由于部署在各个节点上，对于各个节点的时间同步有很高的要求。网络时间协议（Network Time Protocol, NTP）是用来使计算机时间同步化的一种协议，它可以使计算机对其服务器或时钟源（如石英钟、GPS 等）做同步化，也可以提供高精度的