

处理系统测试具有一些独特的特点。

从测试角度看，与传统的软件测试相比，大数据系统测试的特性和面临的挑战主要表现在以下方面：

(1) 分布式环境。大数据处理系统通常部署在分布式环境中，由多个节点组成。测试需要考虑分布式计算和存储的特点，包括并行处理、数据分片、数据复制和分布式调度等。

(2) 多样化的数据类型和格式。大数据处理系统涉及多种数据类型和格式，如结构化数据、半结构化数据和非结构化数据。测试需要覆盖不同数据类型、格式的处理和分析场景。

(3) 实时和批处理。大数据处理系统通常支持实时数据处理和批处理任务。测试需要分别针对实时和批处理模式进行测试，并考虑数据流和处理管道的正确性和效率。

(4) 高性能和可扩展性。大数据处理系统追求高性能和可扩展性。测试需要评估系统在高负载和并发访问下的性能表现，并确定系统的扩展性和横向扩展能力。

(5) 复杂的数据处理逻辑。大数据处理系统的数据处理逻辑可能非常复杂，包括数据清洗、转换、聚合、查询、机器学习等操作。测试需要确保这些处理逻辑的正确性和一致性。

19.4.2 测试过程

传统的测试方法将测试分为单元测试、集成测试、系统测试和验收测试，而过程包括计划、准备、执行和生成测试报告。传统测试方法定义工作结果，如质量计划、测试测量、测试计划、测试用例、测试度量、测试环境和测试报告等，还定义测试角色，如测试经理、测试顾问、测试专家、工具专家等，还定义创建工作结果的详细步骤，如分析可用测试数据、准备或提供测试数据。

大数据测试也是测试，只是在一个特殊的场景、特殊的业务下的测试，测试技术和方法是一样的，测试步骤和流程也不会差别太大，但是它所采用的工具和技巧将会有很大差别。测试流程仍然要遵循如下流程：

(1) 测试需求分析。因为大数据的特点，数据的量大、性价比低，因此前期的需求分析、数据分析极为重要，否则选择错了数据源将可能直接影响最终的结果。因此，对测试需求进行大量的评审、讨论、头脑风暴，然后进行周密的设计，共同促进项目往更合理的方向发展。

(2) 测试计划和方案。测试计划和传统的测试计划是一样的。但是测试计划中划分测试重点格外重要，否则在数据的海洋里，测试将漫无目的，会浪费很多时间。划分合理的测试重点、优先级，对重要的数据进行优先测试很重要。

(3) 测试用例分析和设计。需要对数据的提取、处理、存储和迁移等过程进行测试，测试类型也分为功能测试、性能测试、安全性测试、可靠性、一致性测试等。大数据的用例设计，尤为关注有效数据的设计，100条无效数据不如一条有效数据，这个数据需要不断地分析、讨论而来，最终将其固化在测试用例中。

19.4.3 功能测试

功能测试在整个测试过程中起着至关重要的作用，大数据处理系统的功能测试主要是验证系统是否按照需求规格和设计要求正确地执行各项功能。在具体的实施过程中，还需要关注如下几点。

1. 数据提取测试

在种类繁多、数据量巨大的数据中，提取有效数据、典型数据进行测试，本身就非常具有技术挑战，不仅要求测试工程师要有足够的敏感度，还要有足够的提取技巧及常用工具的使用技巧。

此部分的功能测试，从数据源的提取方式、类型，数据有效性、性价比等方面进行测试。测试系统是否能够正确接收各种类型的数据输入，如结构化数据、半结构化数据和非结构化数据，以及输出符合要求的结果。以下是数据提取测试方面的考虑：

(1) 查询和过滤。测试系统的查询和过滤功能。验证系统能否根据用户给定的查询条件和过滤规则，准确地提取所需的数据，包括单一条件查询、多条件查询、范围查询等。

(2) 数据分区和分片。测试系统在分布式环境下的数据分区和分片能力。验证系统在数据提取过程中是否能够正确地进行数据分区和分片，并保证数据的完整性和一致性。

(3) 聚合和统计。测试系统的数据聚合和统计功能。验证系统能否根据用户需求进行数据的聚合和统计计算，如计数、求和、平均值、最大值、最小值等。

(4) 排序和分组。测试系统的数据排序和分组功能。验证系统能否根据用户指定的排序字段进行数据的排序，并根据用户指定的分组字段对数据进行分组。

(5) 多表关联。测试系统的多表关联查询功能。验证系统能否对多个数据表进行关联查询，根据相关字段的关系获取相关联的数据。

2. 数据处理测试

大数据系统通过各种方式获取数据不是一件很难的事情，通过过滤获取了数据，然后进行数据的清洗、转换、集成才是比较核心的，因为大数据的数据量大、价值密度低的特点，所以数据处理就尤为重要，需要通过数据处理方式从大量低价值密度的数据中分析出有价值的信息。这部分需要测试系统的数据处理和计算能力是否符合要求，如数据清洗、数据转换、数据聚合、数据分析、数据挖掘等功能是否能够实现。

数据处理测试的目标是确保系统能够按照要求进行数据处理和计算，这部分的功能测试可以从以下方面考虑：

(1) 数据清洗和预处理。测试系统的数据清洗和预处理功能。验证系统能否对原始数据进行清洗、去重、缺失值处理、异常值处理等操作，以确保数据的准确性和一致性。

(2) 数据转换和格式化。测试系统的数据转换和格式化功能。验证系统能否将数据按照特定的格式进行转换，如数据类型转换、单位转换、日期格式化等。

(3) 数据聚合和汇总。测试系统的数据聚合和汇总功能。验证系统能否根据用户的需求对数据进行聚合和汇总计算，如求和、平均值、最大值、最小值等。

(4) 数据分析和挖掘。测试系统的数据分析和挖掘功能。验证系统能否对大规模数据进行分析和挖掘，如关联分析、聚类分析、分类和预测等。

3. 数据存储测试

数据提取、处理还是一个短时问题，数据存储则是一个长时问题，需要将大量可能无用或者处理后的短期有用的数据进行长时间存储，将会耗费大量的存储单元，这个过程还需要设

计存储数据的多样化问题。提取的源数据、处理数据和存储数据需要在数据库中进行数据的一致性验证。因此这部分主要需要测试系统是否能够有效地存储和管理大量的数据，包括数据的备份、恢复、维护和安全保障等功能。以下是一些常见的大数据处理系统数据存储测试方面的考虑：

(1) 存储容量和扩展性。测试系统的存储容量是否满足需求，并验证系统的存储扩展性。测试可以模拟大规模数据集，并逐步增加数据量，以评估系统的容量和扩展性。

(2) 数据写入和读取。测试系统的数据写入和读取性能。通过模拟并发写入和读取操作，评估系统在高负载下的性能表现，包括写入和读取的吞吐量、响应时间和并发性能等指标。

(3) 数据冗余和备份。测试系统的数据冗余和备份机制。验证系统在节点故障或其他中断情况下的数据冗余和恢复能力，包括数据备份、恢复和一致性检查等。

(4) 数据一致性和完整性。测试系统的数据一致性和完整性。通过对分布式存储系统进行读写操作，并验证数据在不同节点间的一致性和完整性，以确保数据存储的准确性和可靠性。

(5) 数据压缩和优化。测试系统的数据压缩和优化机制。评估系统在数据存储过程中的压缩率和性能表现，以提高存储效率和节约存储空间。

通过综合以上测试，可以确保大数据处理系统的数据存储功能符合需求，数据可靠、安全和高效地存储和管理。

4. 数据迁移测试

并不是所有的数据都是有效的，在一段时间之后，数据是需要进行迁移的，这样可以节省大量的线上服务资源。例如，某个网站上提供的用户分析数据，只提供了最近 90 天的数据用于访问，其他的数据就删除了吗？对于企业来说，数据就是财富，不会随便删除的，只是迁移了，存放在访问频率更低的存储介质中而已。

数据迁移测试的目标是确保系统能够顺利地将数据从一个环境或存储位置迁移到另一个环境或存储位置，并评估系统在迁移过程中的性能和数据完整性。在实际操作中需要进行以下方面的考虑：

(1) 数据导出和导入。测试系统的数据导出和导入功能。验证系统能否将数据从源环境或存储位置导出到目标环境或存储位置，并确保数据的完整性和准确性。

(2) 数据格式和兼容性。测试系统在数据迁移过程中的数据格式和兼容性。验证系统能否适应不同数据格式和存储系统之间的数据迁移，确保数据能够正确被导入并解析。

(3) 迁移速度和性能。测试系统在数据迁移过程中的速度和性能。评估系统在大规模数据迁移时的处理速度、吞吐量和迁移效率，确保迁移过程的及时性和高效性。

(4) 数据一致性和完整性。测试系统在数据迁移过程中的数据一致性和完整性。验证系统在迁移过程中是否能够保持数据的一致性，确保数据迁移后的准确性和完整性。

(5) 迁移监控和日志记录：测试系统的迁移监控和日志记录功能。验证系统能否对迁移过程进行实时监控和记录关键操作日志，以便进行迁移过程的追踪和故障排查。

(6) 回滚和恢复：测试系统的迁移回滚和数据恢复能力。验证系统能否在迁移失败或出现问题时进行迁移回滚，并能够快速恢复到迁移前的状态。